Борувка на SPLA и Apache Spark. Результаты

Шальнев Владислав, Кадочников Даниил

Характеристики машины Эксперимент 1

ОС: Ubuntu 24.04 LTS

CPU: 10th Gen Intel Core i5-10300H @ 2.50 GHz

- Hyper-Threading включен
- L1: 256 КБ, L2: 1 МБ, L3: 8 МБ

GPU: NVIDIA GeForce GTX 1650 Ti Mobile

- 4 ГБ VRAM GDDR6
- драйвер 580.126.09
- CUDA Toolkit 13.0.97

RAM: 16 ГБ DDR4, 3200 МГц

Программное обеспечение

- gcc 13.3.0
- OpenJDK 11.0.30
- SPLA (commit b81d1e2)
- Apache Spark 3.5.1
- OpenCL 3.0
- Intel OpenCL Runtime 26.05.37020.3
- CMake 3.28.3

Данные Эксперимент 1

Граф	Количество вершин	Количество рёбер
amazon0601	403 394	2 443 408
citationCiteseer	268 495	1 156 647
coPapersDBLP	540 486	15 245 729
in-2004	1 382 908	13 591 473
cit-Patents	3 774 768	16 518 947

Источники: A High-Performance MST Implementation for GPUs 2023, SuiteSparse Matrix Collection

Эксперимент 1

Цель: сравнить время работы алгоритма Борувки на SPLA (CPU, NVIDIA OpenCL и Intel OpenCL) и Apache Spark на реальных графах разного размера

Ход экспериментов

- 20 запусков алгоритма на каждом графе и библиотеке
- Вычисление среднего времени и доверительных интервалов
- Визуализация и анализ результатов

Эксперимент 1

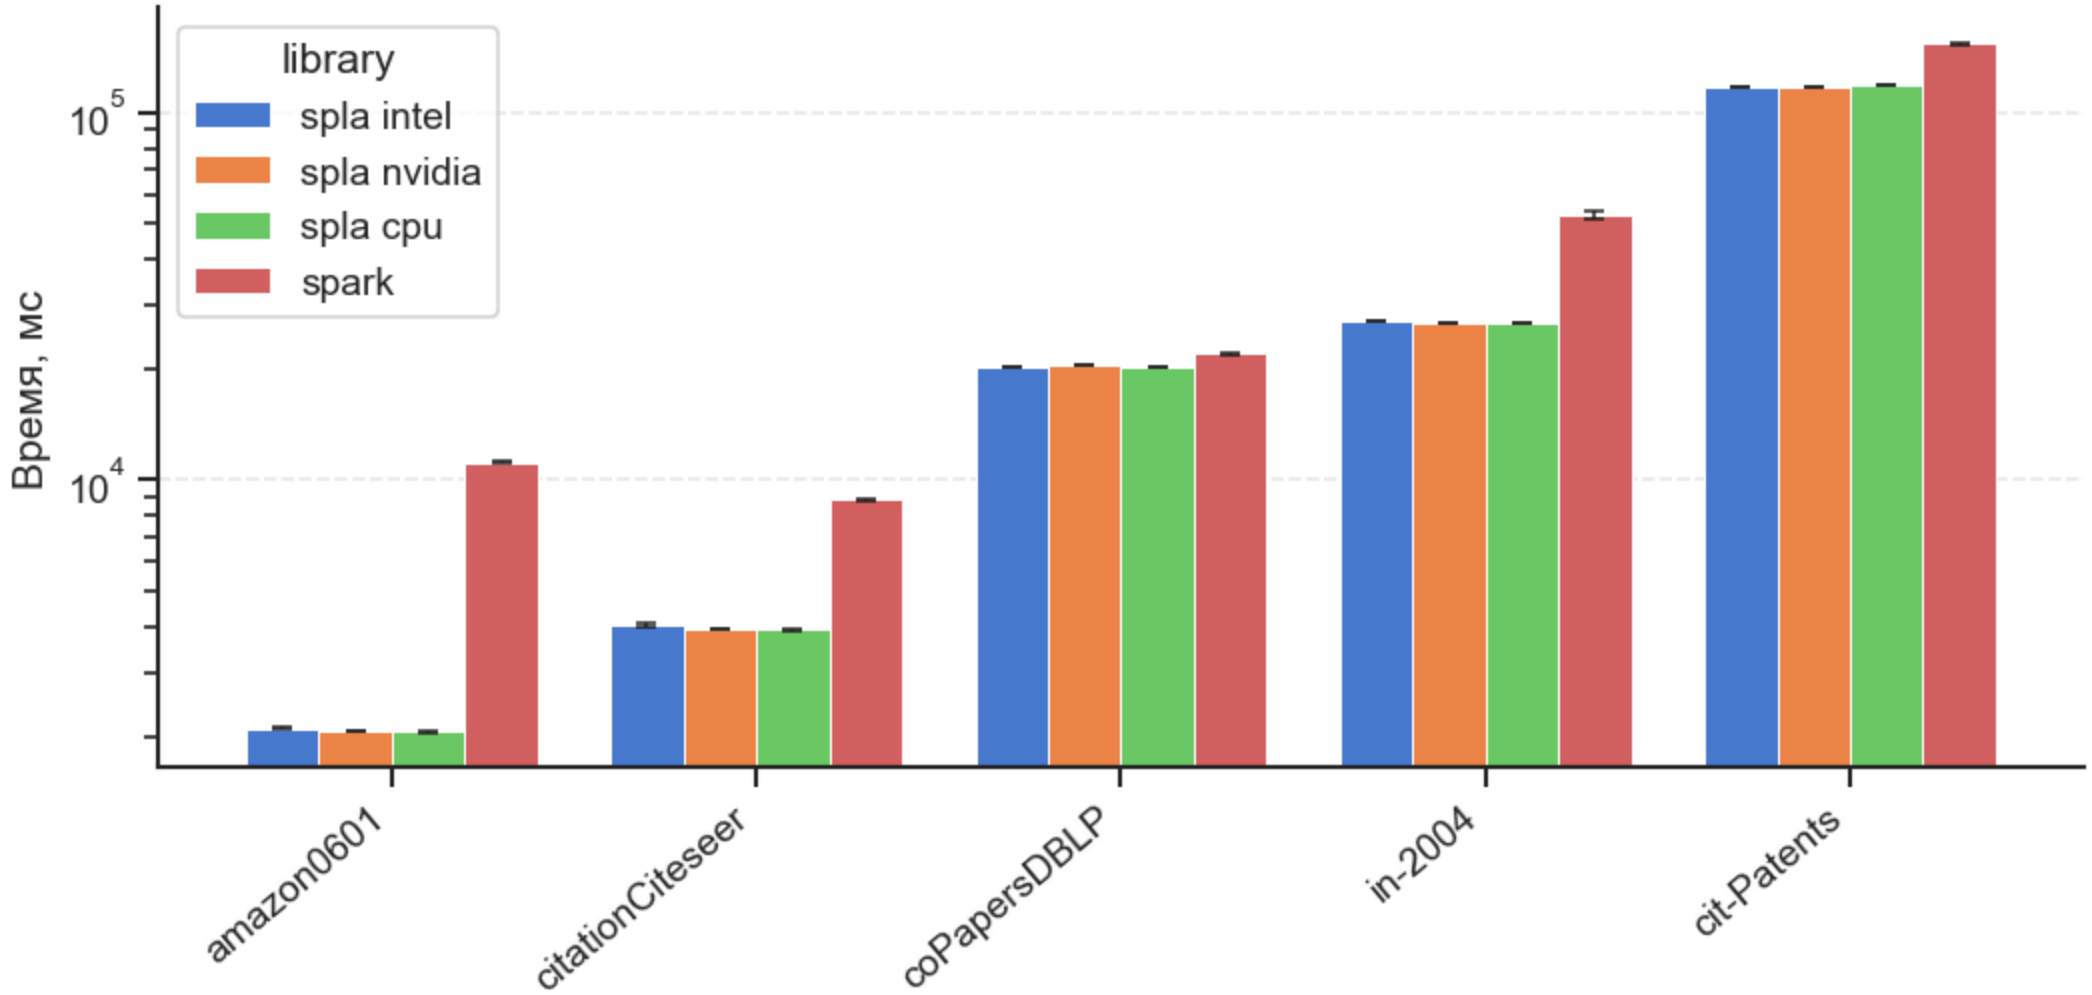

Результаты

- SPLA CPU, Intel OpenCL и NVIDIA OpenCL показывают сопоставимое время — OpenCL не даёт заметного ускорения
- На малых графах SPLA быстрее Spark в 2-5 раз
- На больших графах разрыв сокращается

Профилирование SPLA

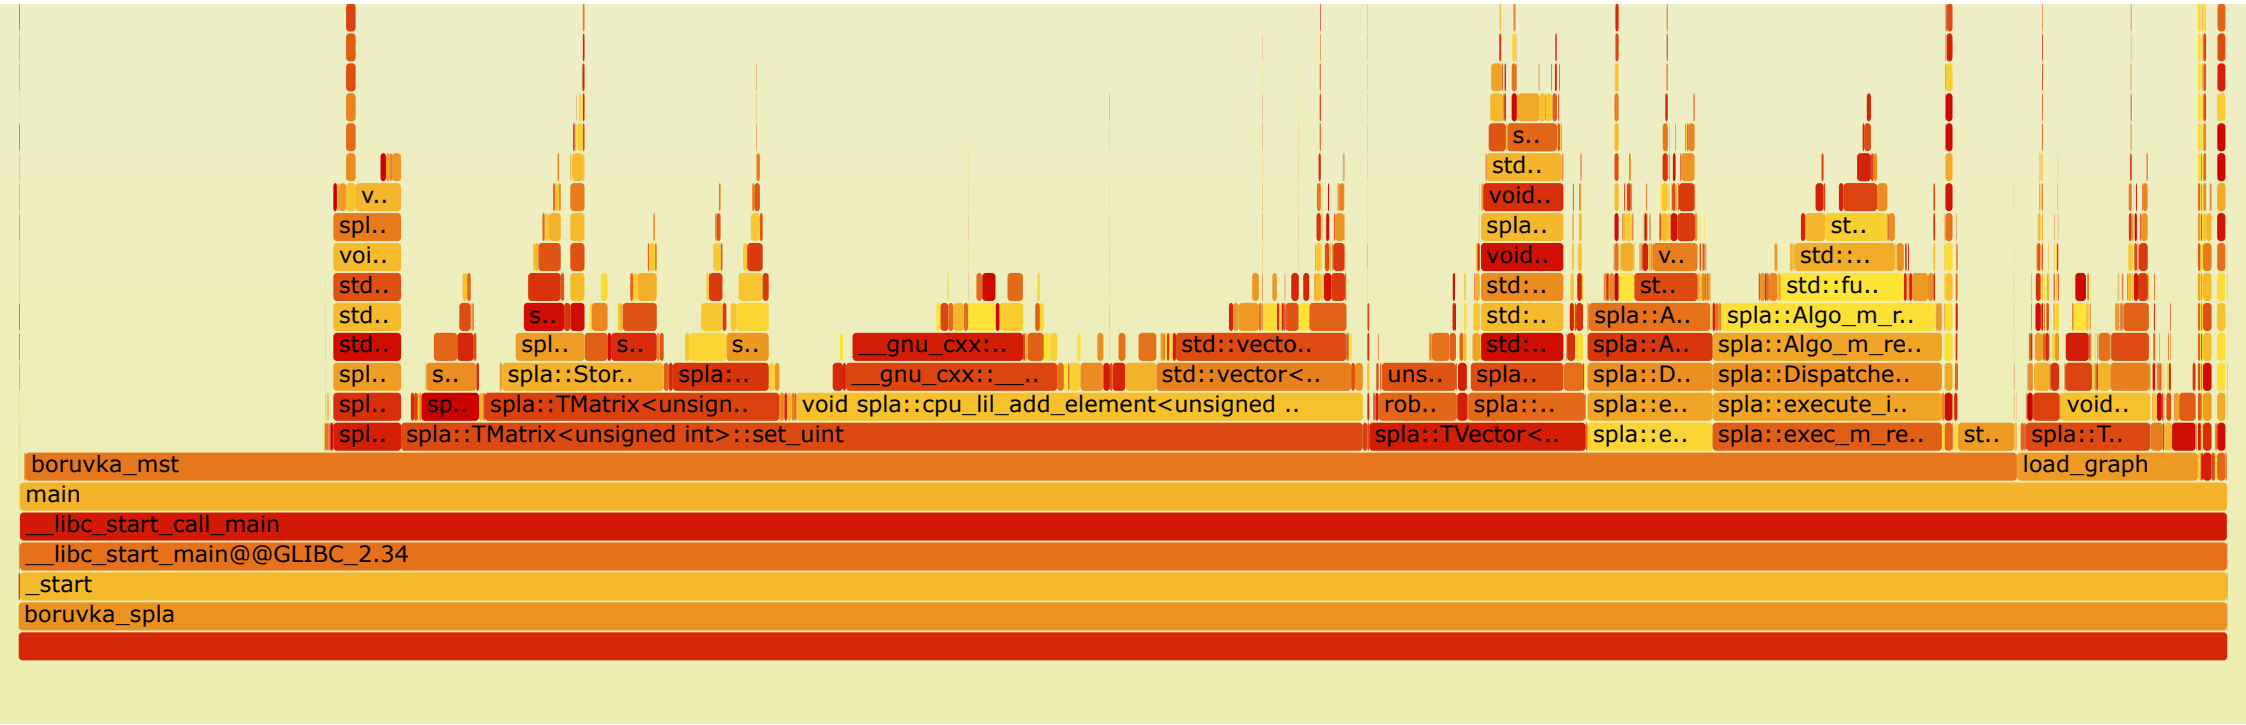

Профилирование SPLA

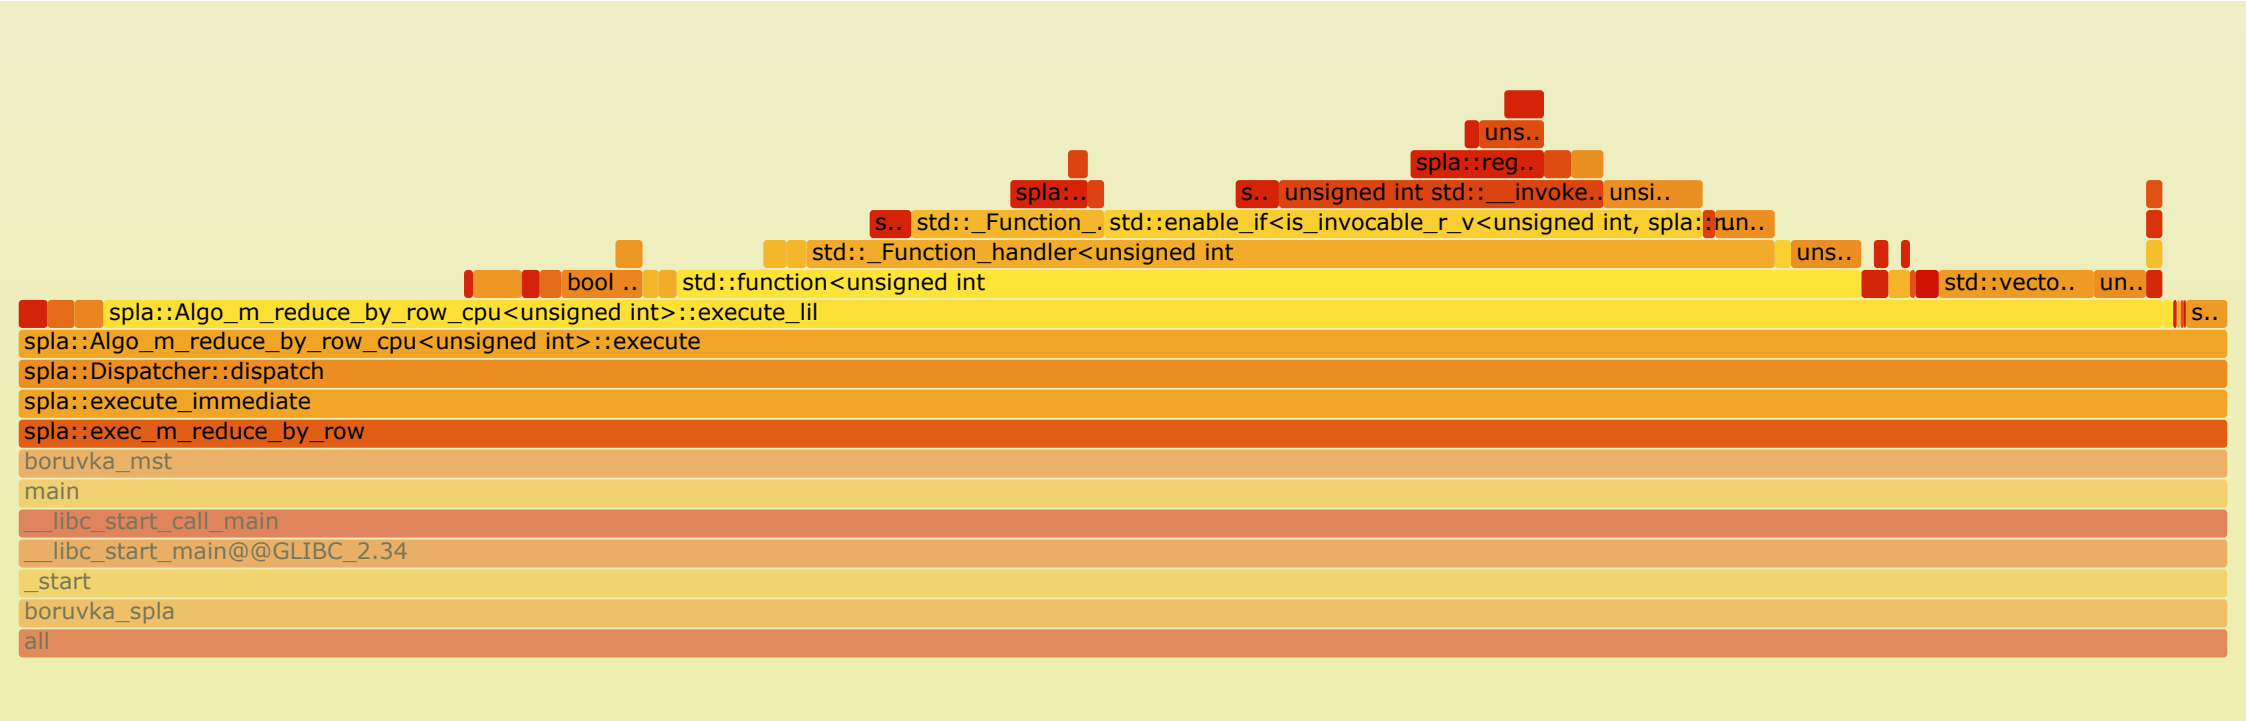

Анализ результатов

- Использование OpenCL accelerator не дает ускорения, реализация `exec_m_reduce_by_row` на OpenCL отсутствует
- В SPLA отсутствует поддержка пользовательских типов
- Операции над матрицами на CPU, нет select, мало операций с масками

Характеристики машины Эксперимент 2

ОС: Windows 10 Pro (22H2)

CPU: 12th Gen Intel Core i5-1235U @ 1.30 GHz

- Ядра: 10 (2 производительных + 8 эффективных)
- Потоки: 12
- L3 Кэш: 12 МБ

RAM: 32 ГБ DDR4, 3200 МГц

Данные Эксперимент 2

Данные эксперимента: Road Networks

Граф	Вершины	Рёбра
road-usroads	129 164	165 435
USA-road-d.NY	264 346	730 100
USA-road-d.COL	435 666	1 042 400
road-belgium-osm	1 038 823	1 549 970
road-roadNet-CA	1 957 027	2 760 388

Данные эксперимента: Geometric Graphs

Граф	Вершины	Рёбра
delaunay_n17	131 072	393 176
delaunay_n18	262 144	786 396
delaunay_n19	524 288	1 572 823
delaunay_n20	1 048 576	3 145 686
delaunay_n21	2 097 152	6 291 408

Данные эксперимента: Social & Collaboration Networks

Граф	Вершины	Рёбра
soc-sign-epinions	131 828	840 799
ca-citeseer	227 320	814 134
soc-flickr	513 969	3 190 452
soc-lastfm	1 191 805	4 519 330
soc-flickr-und	2 394 385	15 555 042

Источник: Network Repository (NRVIS)

Эксперимент 2

Цель: исследовать влияние типа графа на относительную производительность реализаций алгоритма Борувки на SPLA (CPU) и Apache Spark

Вопрос: зависит ли соотношение времени работы SPLA и Spark от структурных свойств графа?

Типы графов:

- **Road** — разреженные дорожные сети, много итераций Борувки
- **Geometric** — триангуляции Делоне, средняя плотность
- **Social** — социальные/коллаборационные сети, высокая плотность, мало итераций

Ход эксперимента 2

Влияние типа графа

- 5 запусков алгоритма на каждом графе и библиотеке, 3 прогрева
- Сравнение SPLA (CPU) и Spark
- Визуализация и анализ результатов

Эксперимент 2 — Сравнение по типу графа

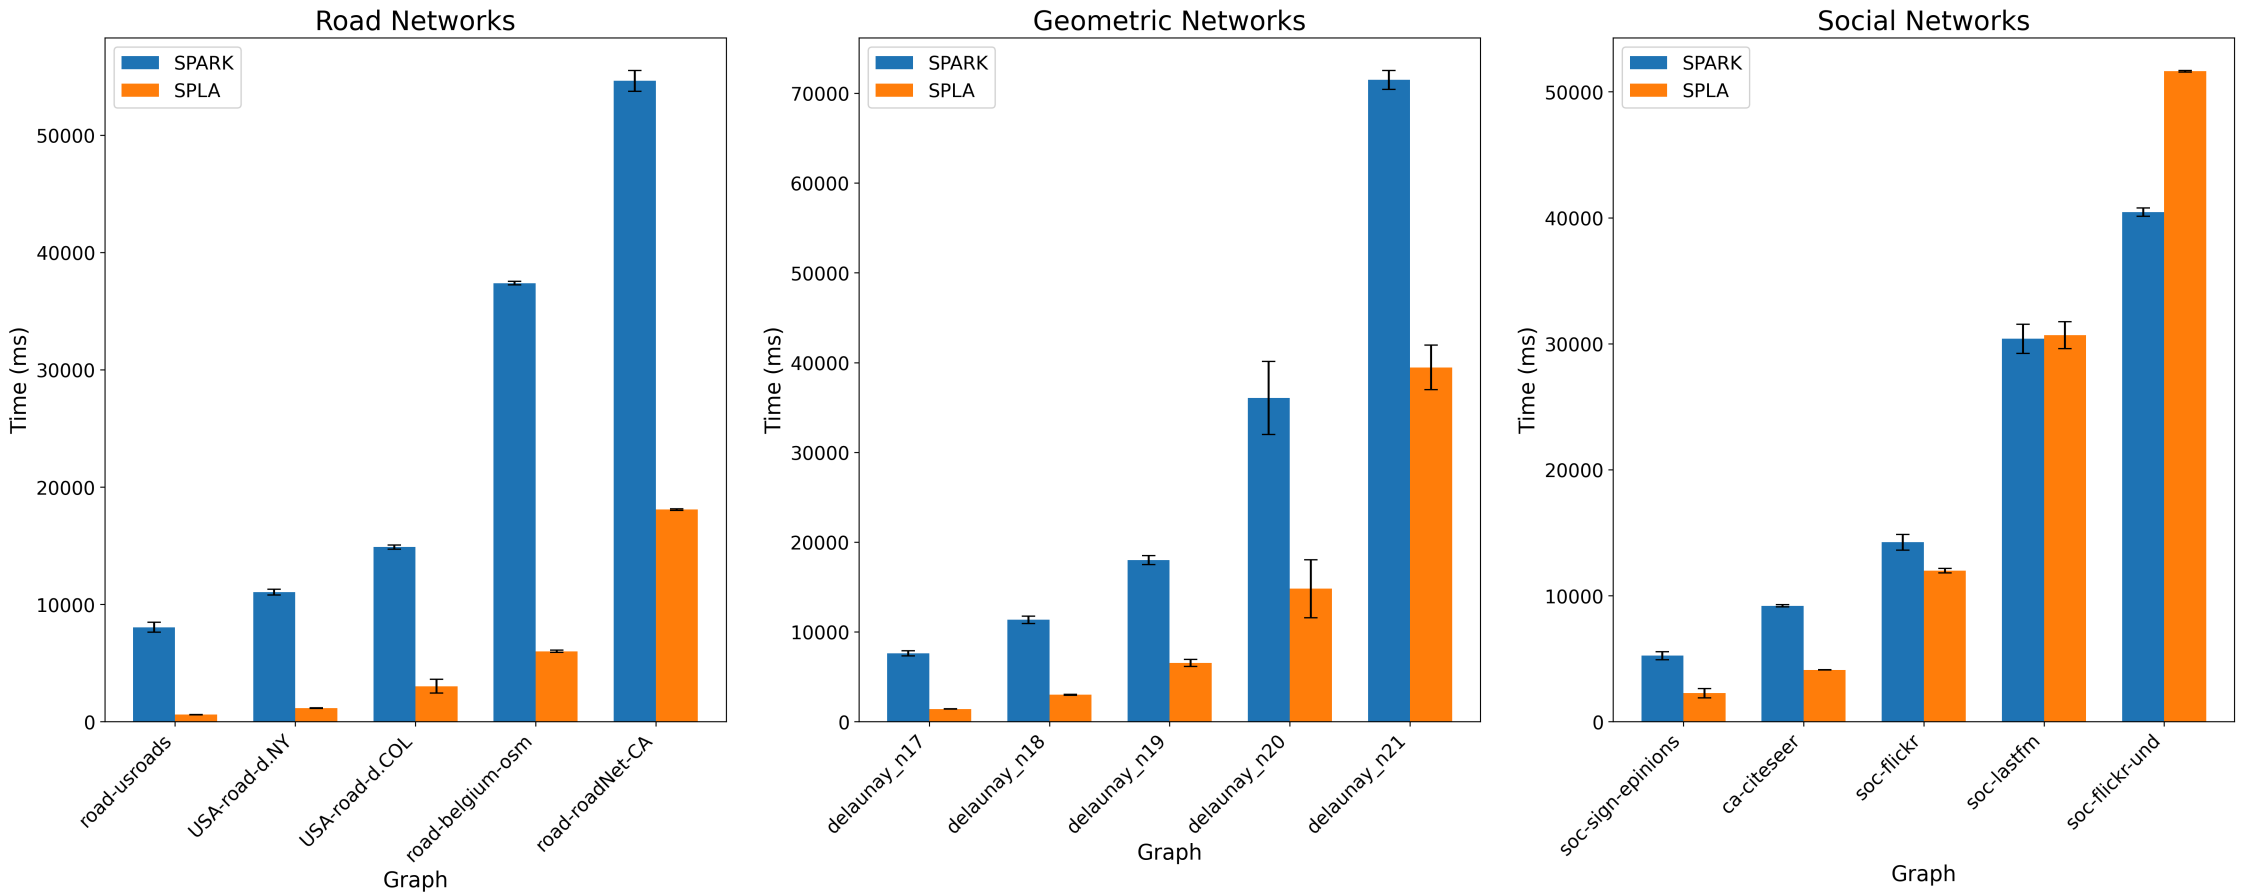

Эксперимент 2 — Ускорение SPLA относительно Spark

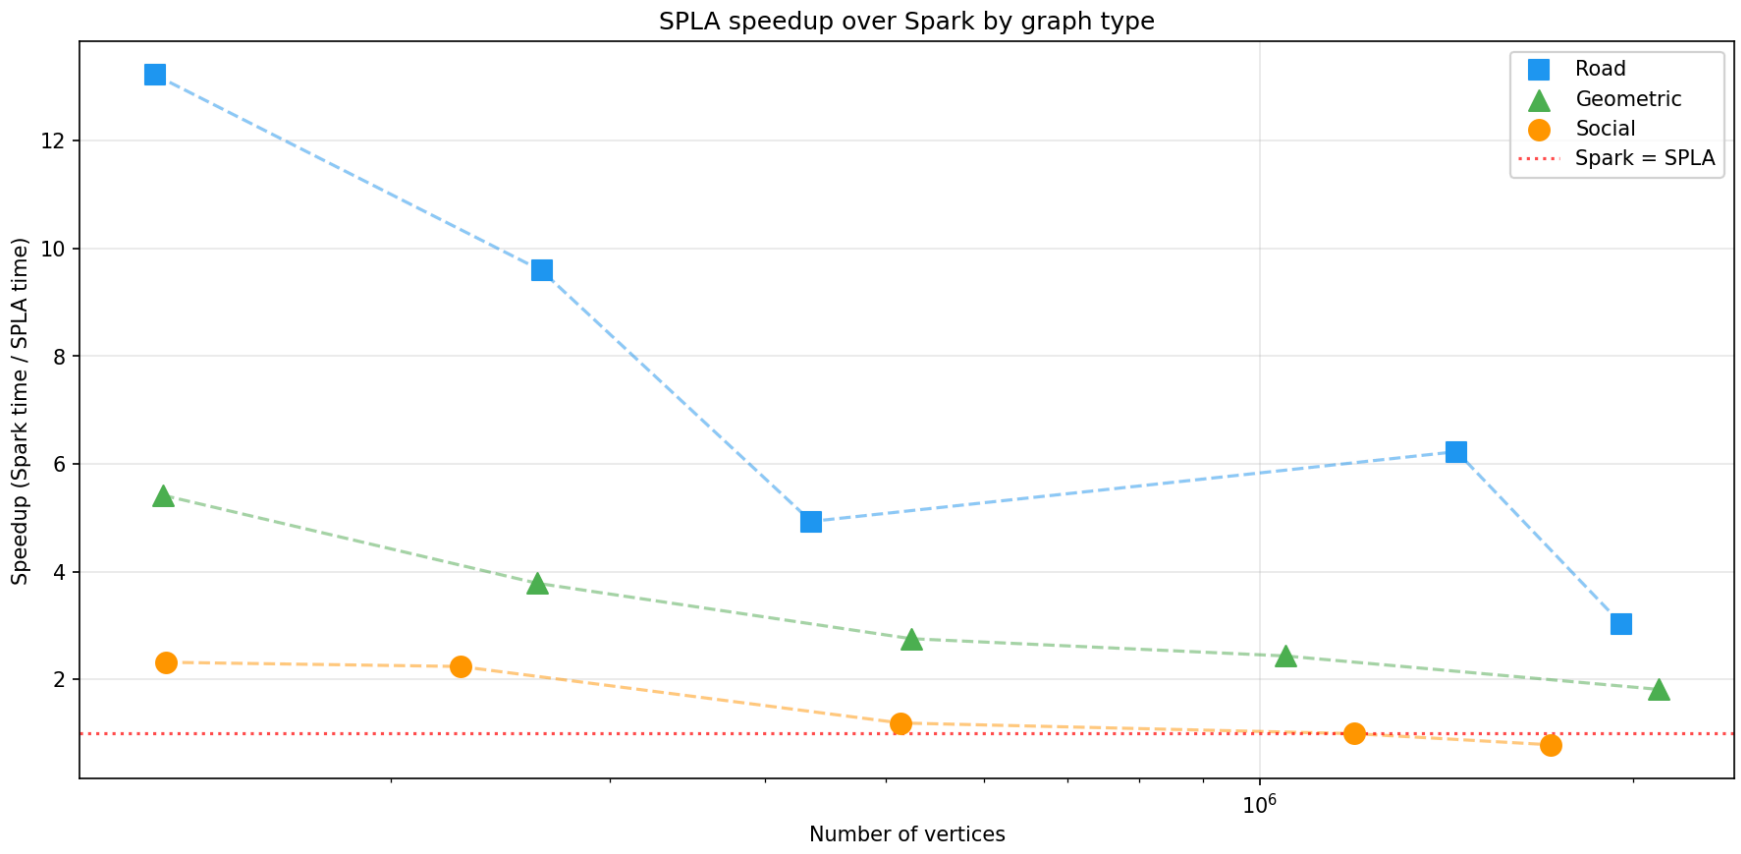

Эксперимент 2 — Время по размеру и типу графа

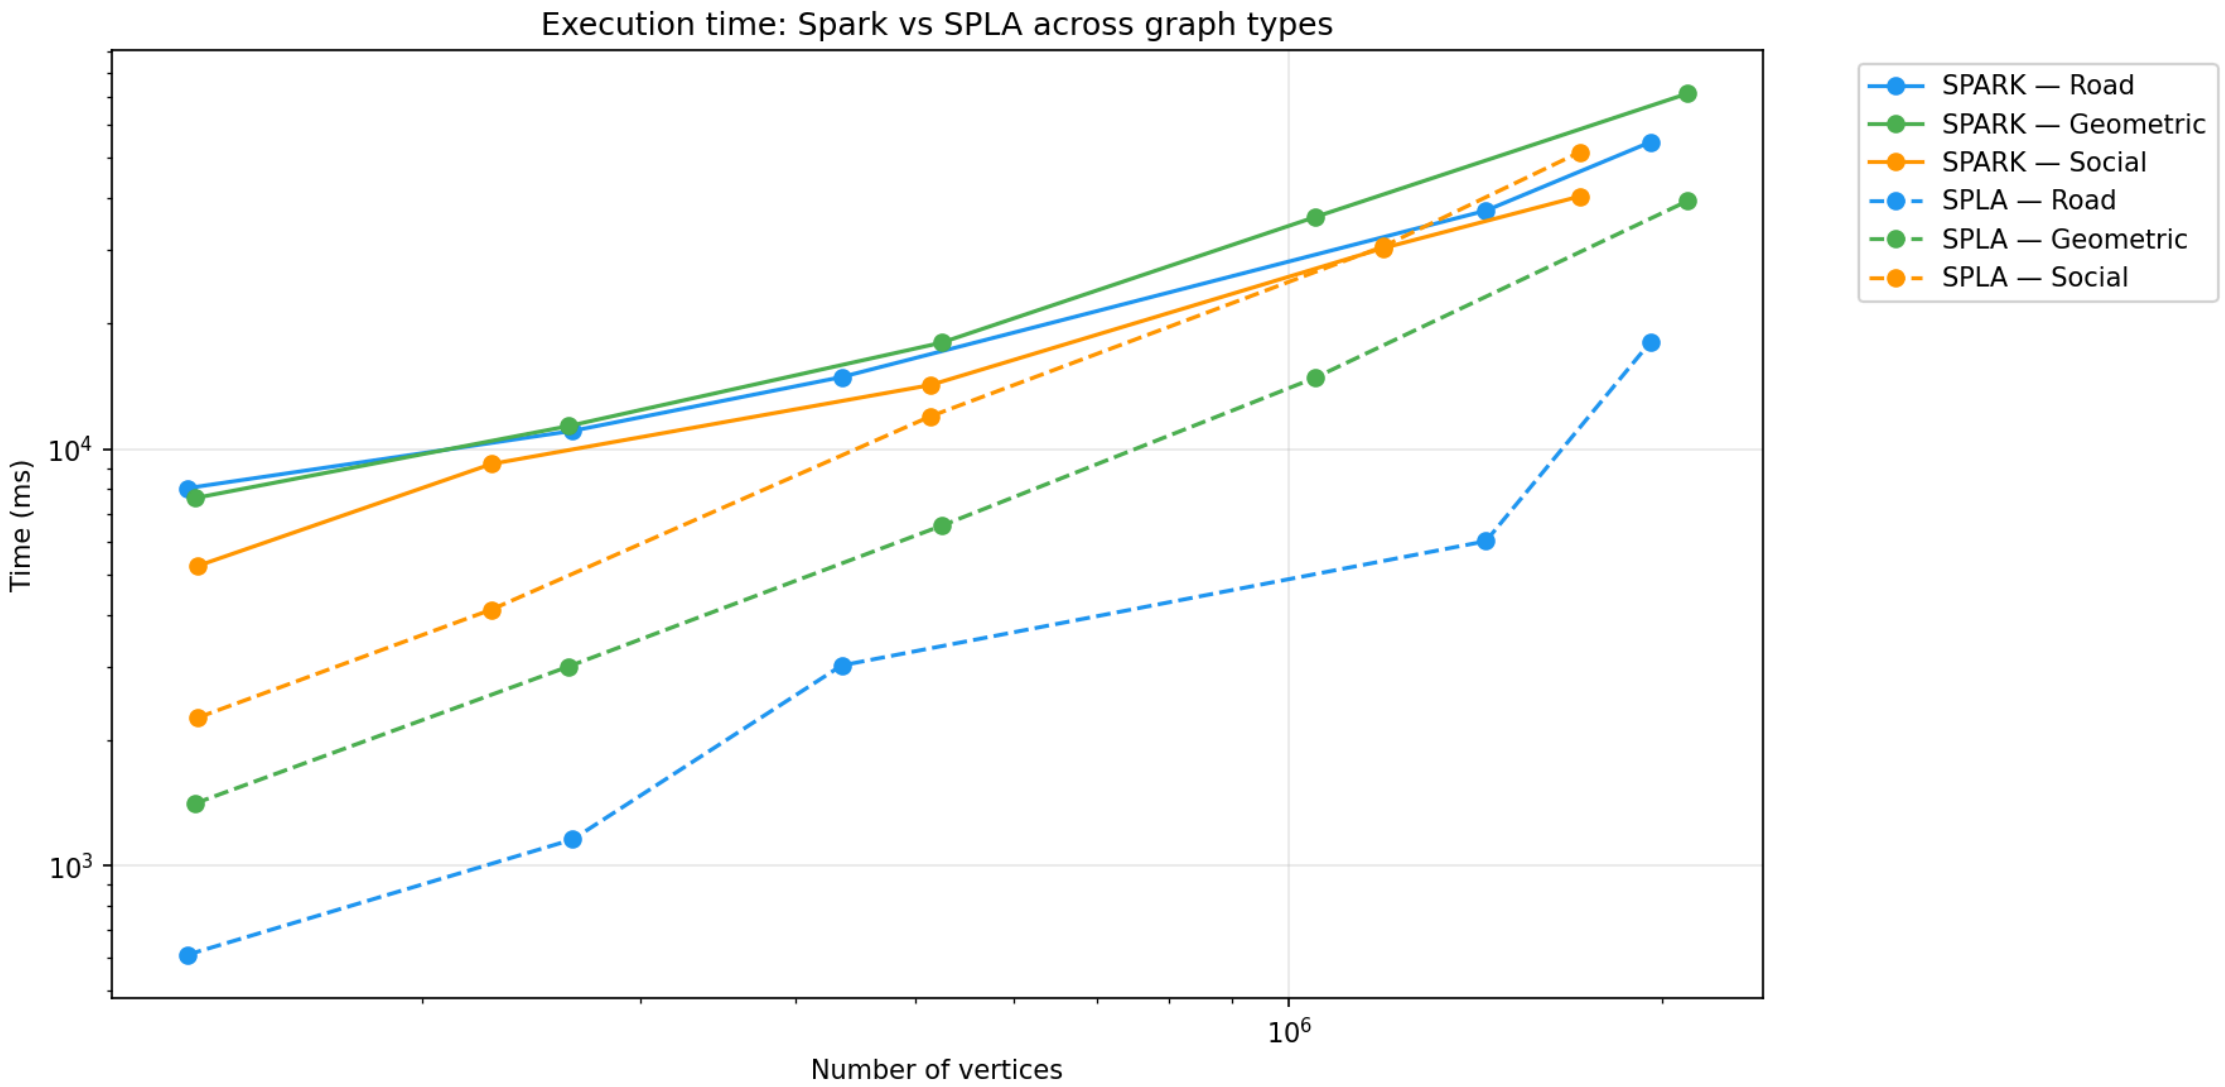

Эксперимент 2 — Нормализованное время (ms/вершину)

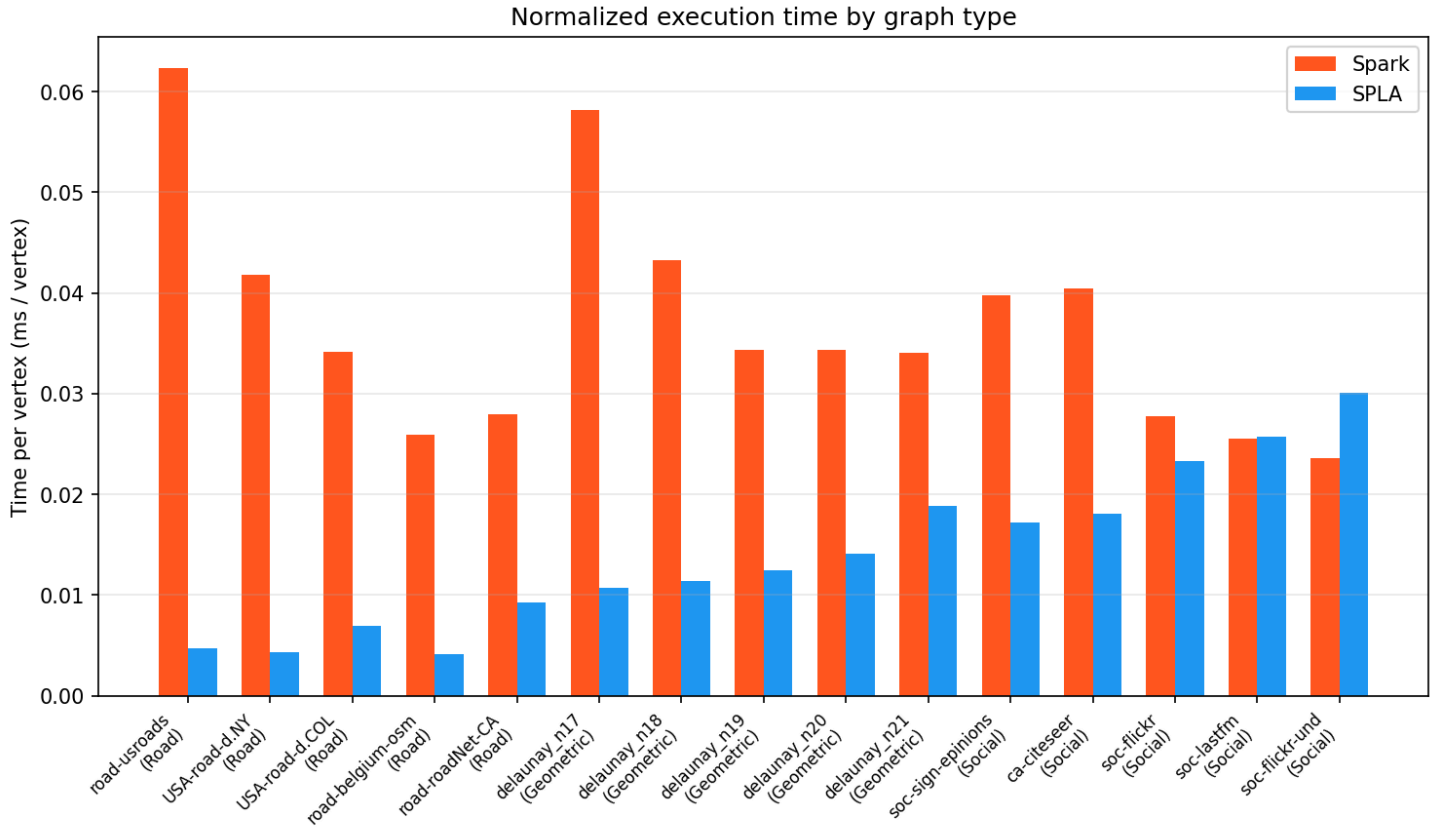

Выводы Эксперимент 2

1. **Тип графа влияет на соотношение производительности** SPLA и Spark
2. **Road-графы** — наибольший разрыв: Spark тратит больше на многочисленные итерации
3. **Social-графы** — наименьший разрыв: мало итераций, overhead Spark менее заметен
4. **Главный фактор** — число итераций алгоритма Борувки, которое определяется структурой графа
5. При выборе реализации MST следует учитывать **тип входных данных**